

Pengembangan Aplikasi Analisis Pola Belanja E-Commerce Menggunakan Association Rule Mining dan K-Means Clustering Berbasis Data Mining

Muhammad Viko Nur Huda¹, Muhammad Fajrul Falah²

^{1,2} Fakultas Teknik, Program Studi S1 Sistem Informasi, Universitas Negeri Surabaya

¹24051214076@mhs.unesa.ac.id

²24051214071@mhs.unesa.ac.id

Abstrak— Perkembangan e-commerce menghasilkan volume data transaksi yang sangat besar, namun potensi data tersebut sering kali belum dimanfaatkan secara optimal untuk mendukung strategi bisnis. Penelitian ini mengembangkan aplikasi analisis pola belanja berbasis data mining yang menggabungkan dua pendekatan utama, yaitu segmentasi pelanggan menggunakan RFM Analysis dan K-Means Clustering, serta analisis pola pembelian menggunakan Association Rule Mining dengan algoritma FP-Growth. Dataset yang digunakan adalah Online Retail Dataset dari UCI Machine Learning Repository, mencakup 541.909 data transaksi ritel online berbasis di Inggris pada periode Desember 2010 hingga Desember 2011. Proses analisis mengikuti kerangka kerja CRISP-DM secara menyeluruh, mulai dari pemahaman bisnis, preparasi data, pemodelan, evaluasi, hingga deployment. Hasil segmentasi menggunakan K-Means menghasilkan 4 cluster yang secara bisnis dipetakan menjadi 3 segmen pelanggan: Champions, Potential Loyalists, dan At-Risk/Churned, dengan Silhouette Score sebesar 0.337. Sementara itu, analisis FP-Growth menghasilkan association rules dengan nilai lift tertinggi mencapai 27.19, yang mengindikasikan hubungan kuat antar produk tertentu. Aplikasi diimplementasikan menggunakan framework Streamlit dan di-deploy melalui Streamlit Community Cloud, sehingga dapat diakses secara daring tanpa instalasi tambahan. Hasil penelitian ini diharapkan dapat membantu pelaku usaha ritel online dalam mengambil keputusan bisnis yang lebih terarah dan berbasis data..

Kata Kunci— terdiri minimal 5 kata kunci atau frasa, kata kunci dipisahkan dengan koma.

I. PENDAHULUAN

Perkembangan teknologi yang sangat masif telah membawa perubahan yang signifikan dalam berbagai sektor, termasuk dalam sektor perdagangan dan bisnis. Salah satu dampaknya ada pada pengguna toko online ritel yang meningkat. Toko online ritel memberikan kemudahan bagi konsumen karena pelanggan bisa berbelanja dari mana saja dan kapan saja tidak perlu lagi datang ke toko offline yang memiliki jadwal buka dan tutup. Kemudahan tersebut menyebabkan volume data transaksi yang besar dan terus bertambah setiap harinya. Data transaksi berisikan berbagai informasi penting dari data pelanggan, produk yang dibeli, waktu transaksi, hingga metode pembayaran yang digunakan. Semakin sering bertransaksi maka volume data akan semakin besar, tetapi data transaksi tersebut tidak hanya menjadi arsip ataupun laporan keuangan, data transaksi tersebut bisa dimanfaatkan untuk memperoleh perilaku pelanggan dan pola pembelian produk serta

meningkatkan efektivitas strategi bisnis yang diterapkan. Data transaksi e-commerce dapat digunakan untuk mengungkap segmentasi pelanggan atau kelompok pelanggan berdasarkan karakteristik dan perilaku yang serupa sehingga dapat mendukung pengambilan keputusan bisnis yang lebih efektif.

Dalam penelitian dan implementasi data mining, terdapat banyak metode yang bisa digunakan untuk analisis tujuan yang ingin dicapai salah satu metode nya adalah *Association Rule Mining* yang sering digunakan untuk menganalisis pola pembelian. Metode ini dapat menganalisis hubungan antar produk yang sering muncul secara bersamaan pada setiap transaksi pelanggan. Hasil dari *Association Rule Mining* ialah berupa aturan, praktik nya seperti jika pelanggan membeli Produk A maka terdapat kemungkinan besar pelanggan juga akan membeli produk B dalam sebuah transaksi yang sama. Data transaksi ritel dapat dimanfaatkan untuk mengidentifikasi pola pembelian konsumen dan hubungan antar produk sehingga perusahaan dapat memahami kecenderungan perilaku belanja pelanggan [1].

Selain menganalisis hubungan antar produk, perusahaan juga perlu mempelajari karakteristik pelanggan pada setiap transaksi. Setiap pelanggan memiliki pola belanja yang berbeda-beda. Sebagian pelanggan berbelanja jarang tetapi sekali belanja nilai transaksinya besar, ada juga yang transaksinya sering tetapi nilainya relatif kecil. Perbedaan tersebut yang perlu disegmentasikan agar strategi bisnis yang akan diterapkan bisa sesuai dengan kebutuhan masing-masing kelompok pelanggan. Penggunaan algoritma K-Means dalam segmentasi pelanggan dapat membantu perusahaan mengidentifikasi kelompok pelanggan berdasarkan perilaku transaksi yang dimiliki [2]. Informasi tersebut memungkinkan perusahaan untuk menerapkan strategi pemasaran yang lebih personal dan terarah sehingga dapat meningkatkan kepuasan pelanggan sekaligus meningkatkan keuntungan perusahaan.

Berdasarkan uraian tersebut, penelitian ini mengembangkan aplikasi analisis pola belanja e-commerce menggunakan metode *Association Rule Mining* dan *K-Means Clustering*. Kedua metode tersebut diterapkan pada aplikasi dengan harapan mampu menghasilkan data mengenai keterkaitan antar produk dan segmentasi pelanggan, sehingga dapat membantu pemilik toko online ritel dalam mengambil keputusan bisnis, penyusunan strategi promo, serta meningkatkan kualitas layanan kepada pelanggan

II. TINJAUAN PUSTAKA

A. Data Mining

Data mining merupakan proses menganalisa data dari perspektif yang berbeda dan menyimpulkannya menjadi informasi-informasi penting yang dapat dipakai untuk meningkatkan keuntungan, memperkecil biaya pengeluaran, atau mungkin keduanya [3]. Secara teknis, data mining dapat disebut sebagai proses untuk menemukan korelasi atau pola dari sekumpulan data dalam jumlah besar dari sebuah dataset. Teknologi ini dapat digunakan untuk prediksi trend dan sifat-sifat bisnis, hingga penemuan pola-pola data yang tidak diketahui sebelumnya [4].

Dalam konteks *e-commerce*, data mining digunakan untuk menganalisis perilaku Pelanggan berdasarkan data transaksi, sehingga perusahaan dapat memahami pola pembelian dari Pelanggan dan menemukan strategi pemasaran yang lebih efektif.

B. CRISP-DM

Cross Industry Standard Process for Data Mining (CRISP-DM) merupakan sebuah metode atau kerangka kerja (*framework*) yang membagi proses menjadi enam fase berurutan. Fase pertama dari metode ini dimulai dari *Business Understanding*, kemudian *Data Understanding*, *Data Preparation*, *Modelling*, *Evaluation*, hingga yang terakhir *Deployment* [5].

Business Understanding bertujuan untuk memahami tujuan bisnis dan menentukan permasalahan yang akan diselesaikan melalui data mining, *Data Understanding* dilakukan untuk memahami karakteristik data dan eksplorasi awal, *Data Preparation* mencakup proses pembersihan data, transformasi data, hingga pemilihan atribut yang relevan, kemudian *Modelling* dilakukan dengan menerapkan teknik data mining yang relevan untuk kebutuhan analisis, *Evaluation* bertujuan untuk menilai apakah model yang telah dibuat sudah sesuai dengan kebutuhan bisnis, serta *Deployment* dilakukan untuk implementasi hasil model ke dalam sebuah sistem berdasarkan kebutuhan pemangku kepentingan.

Dalam penelitian ini, metode CRISP-DM digunakan sebagai kerangka kerja utama untuk mengolah data transaksi *e-commerce* mulai dari pemahaman bisnis, penerapan teknik data mining, hingga implementasi hasil model.

C. Market Basket Analysis

Market Basket Analysis merupakan suatu metode analisis atas perilaku konsumen secara spesifik dari dari suatu golongan atau kelompok tertentu [6]. Secara umum, *Market Basket Analysis* digunakan dimanfaatkan sebagai titik awal pencarian informasi dari suatu data transaksi ketika Kita tidak mengetahui pola spesifik apa yang Kita cari.

Dalam prosesnya, *Market Basket Analysis* menggunakan tiga parameter utama untuk mengevaluasi kekuatan hubungan antar item yang meliputi *support*, *confidence*, dan *lift* [7]. *Support* mengukur seberapa sering item atau kombinasi item muncul dalam dataset transaksi (diukur sebagai rasio jumlah transaksi yang mengandung item atau kombinasi item tertentu terhadap total jumlah transaksi). *Support* yang tinggi menunjukkan bahwa item atau kombinasi item tersebut sering

dibeli bersama. Lalu, *confidence* mengukur seberapa sering item B dibeli ketika item A dibeli. *Confidence* yang tinggi menunjukkan hubungan yang kuat antara item-item tersebut. Terakhir, *lift* digunakan untuk mengukur seberapa besar peningkatan probabilitas pembelian item B ketika item A dibeli dibandingkan dengan probabilitas pembelian item B secara keseluruhan. *Lift* dihitung sebagai rasio antara *confidence* dan *support* item B. *Lift* yang lebih besar dari 1 menunjukkan bahwa pembelian item A meningkatkan kemungkinan pembelian item B.

Dalam penelitian ini, *Market Basket Analysis* digunakan untuk menganalisis pola pembelian pada data transaksi *e-commerce* guna menemukan hubungan antar produk yang sering dibeli secara bersamaan oleh Pelanggan.

D. RFM Analysis

RFM merupakan singkatan dari *Recency*, *Frequency*, dan *Monetary*. *RFM Analysis* adalah sebuah teknis analisis data yang digunakan untuk mengelompokkan konsumen atau pelanggan berdasarkan tiga faktor utama, yaitu *Recency*, *Frequency*, dan *Monetary* [8]. Ketiga komponen tersebut kemudian diberi skor untuk masing-masing pelanggan, sehingga menghasilkan representasi numerik yang dapat digunakan untuk proses analisis lebih lanjut.

Dalam penelitian ini, *RFM Analysis* digunakan untuk mengukur nilai pelanggan berdasarkan perilaku pembelian pada data transaksi *e-commerce*.

E. K-Means Clustering

K-Means Clustering merupakan salah satu teknik *clustering* yang digunakan dalam analisis data. Algoritma ini bekerja dengan cara membagi data ke dalam K kelompok yang telah ditentukan sebelumnya, di mana K merupakan jumlah kelompok yang diinginkan [9]. Proses dimulai dengan memilih secara acak K titik pusat kelompok (*centroid*) di dalam ruang data, lalu mengelompokkan setiap titik data ke dalam kelompok yang memiliki *centroid* terdekat. Lalu, titik pusat setiap kelompok dihitung kembali berdasarkan rata-rata titik data dalam kelompok tersebut. Proses ini diulangi hingga tidak ada lagi perubahan dalam penempatan titik data ke dalam kelompok atau hingga batasan iterasi yang ditentukan tercapai.

Dalam penelitian ini, algoritma *K-Means Clustering* digunakan untuk melakukan segmentasi pelanggan berdasarkan nilai *Recency*, *Frequency*, dan *Monetary*, sehingga diperoleh segmentasi pelanggan yang lebih jelas dan dapat digunakan untuk strategi pemasaran yang lebih efektif.

F. Frequent Pattern Growth (FP-Growth)

Algoritma FP-Growth merupakan salah satu dari metode pengembangan pola yang sering digunakan untuk memecahkan masalah di mana suatu pola (misalnya kumpulan item) terjadi ketika frekuensi kejadian basis data berada di bawah minimum Tingkat dukungan yang diinginkan [10].

Dalam penelitian ini, FP-Growth berkorelasi dengan analisis pola pembelian pada dataset *e-commerce*, yang digunakan untuk mengidentifikasi kombinasi produk yang

sering dibeli secara bersamaan sebagai dasar dalam market basket analysis dan strategi rekomendasi produk.

G. Exploratory Data Analysis

Exploratory Data Analysis merupakan sebuah tahapan dalam *data science* untuk mengenal dan memahami dataset. Secara definitif, *Exploratory Data Analysis* mengacu pada proses kritis dalam melakukan investigasi awal pada data untuk menemukan pola, menemukan anomali, menguji hipotesis, dan memeriksa asumsi dengan bantuan statistik ringkasan dan representasi grafis [11].

Dalam penelitian ini, *Exploratory Data Analysis* digunakan sebagai tahap awal untuk memahami struktur dataset, meliputi distribusi transaksi, karakteristik pelanggan, serta pola pembelian yang kemudian digunakan sebagai dasar untuk metode data mining.

H. Principal Component Analysis

Principal Component Analysis (PCA) adalah suatu teknik statistik multivariat yang secara linear mengubah bentuk sekumpulan variabel asli menjadi kumpulan variabel yang lebih kecil yang tidak berkorelasi yang dapat mewakili informasi dari kumpulan variabel asli. Tujuan utamanya adalah untuk menjelaskan sebanyak mungkin jumlah varian data asli dengan sedikit mungkin komponen utama yang disebut faktor [12].

III. METODOLOGI

A. Dataset

Dataset adalah kumpulan dari beberapa data yang menggambarkan sebuah topik tertentu. Dataset yang digunakan dalam penelitian ini adalah Online Retail Dataset yang diperoleh secara publik melalui platform *UC Irvine Machine Learning Repository*. Dataset ini merupakan dokumentasi transaksi penjualan dari sebuah perusahaan retail online yang berbasis di Inggris, yang mencatat aktivitas pembelian pelanggan selama periode Desember 2010 hingga Desember 2011. Setiap rekaman data merepresentasikan satu transaksi pembelian yang dilakukan oleh Pelanggan, mencakup informasi mengenai produk yang dibeli, jumlah item, harga satuan, waktu transaksi, serta negara asal Pelanggan. Dataset ini digunakan untuk menggambarkan pola perilaku pembelian Pelanggan serta karakteristik penjualan pada platform retail online tersebut. Untuk karakteristik lebih lengkap dari dataset, akan disajikan dalam Tabel 1 berikut.

TABEL I
KARAKTERISTIK DATASET

Atribut	Keterangan
Sumber Data	UC Irvine Machine Learning Repository
Jumlah Rekaman	541.909 Baris
Jumlah Fitur	8 Fitur
Granularitas Data	Transaction-Item-Level
Rentang Waktu	01 Desember 2010 – 09 Desember 2011
Format Dataset	Tabular (Structured Data),

	dengan berbagai macam tipe data (numerik, kategorikal, temporal, dan identifier)
--	--


Selain itu, Dataset ini terdiri atas delapan fitur serta dikategorikan ke dalam empat kelompok. Untuk deskripsi setiap fitur, akan disajikan dalam Tabel 2 berikut.

TABEL II
DESKRIPSI FITUR DATASET

No	Nama Fitur	Tipe Data	Kategori	Keterangan
1.	InvoiceNO	String	Identifier atau Kategorikal	Nomor unik untuk setiap transaksi. Jika diawali huruf "C", menunjukkan transaksi dibatalkan (<i>cancelled order</i>)
2.	StockCode	String	Kategorikal	Kode unik untuk setiap produk yang dijual. Digunakan untuk mengidentifikasi item
3.	Description	String	Kategorikal (Text)	Nama atau deskripsi produk yang dibeli oleh Pelanggan
4.	Quantity	Integer	Numerik (Diskrit)	Jumlah item yang dibeli dalam satu transaksi. Memungkinkan untuk bernilai negatif jika terjadi <i>refund</i> atau <i>cancel</i> pada transaksi
5.	InvoiceDate	Datetime	Temporal	Waktu dan tanggal transaksi yang dilakukan (format tanggal dan jam)
6.	UnitPrice	Float	Numerik (Kontinu)	Harga per unit dari sebuah produk dalam satuan pound sterling
7.	CustomerID	Integer	Identifier atau Kategorikal	ID unik Pelanggan.
8.	Country	String	Kategorikal	Negara asal Pelanggan yang melakukan transaksi.

B. Kerangka CRISP-DM

Penelitian ini mengikuti tahapan framework CRISP-DM yang terdiri dari enam fase utama yang dilakukan secara berurutan, yaitu *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation*, dan *Deployment*. Diagram alur metodologi penelitian ditunjukkan pada Gbr. 1. Setiap fase dalam CRISP-DM menghasilkan output yang menjadi input bagi fase berikutnya, sehingga membentuk suatu alur proses yang sistematis dan terstruktur. Selain itu, framework ini juga memungkinkan adanya mekanisme iterasi, di mana apabila hasil pada tahap evaluasi belum memenuhi tujuan penelitian, maka proses dapat kembali ke tahap sebelumnya untuk dilakukan perbaikan dan penyempurnaan.



Gbr. 1 Diagram Alur Metode CRISP-DM

C. Business Understanding

Pada fase ini dilakukan identifikasi permasalahan bisnis yang akan diselesaikan serta tujuan analitik yang terukur. Permasalahan utama dalam konteks industri ritel adalah belum optimalnya pemanfaatan data transaksi pelanggan dalam mendukung strategi pemasaran yang bersifat personal dan berbasis data (*data-driven marketing*). Data transaksi yang besar sering kali belum diolah secara maksimal untuk memahami perilaku pelanggan serta hubungan antar produk yang dapat meningkatkan efektivitas penjualan.

Selain itu, perusahaan ritel umumnya menghadapi tantangan dalam mempertahankan pelanggan, meningkatkan nilai transaksi, serta mengoptimalkan strategi cross-selling antar produk. Hal ini menunjukkan perlunya pendekatan analitik yang mampu menggali pola perilaku pelanggan secara lebih mendalam.

Tujuan bisnis dalam penelitian ini ditetapkan sebagai berikut: mengidentifikasi segmen pelanggan berdasarkan karakteristik perilaku transaksi menggunakan pendekatan

Recency, Frequency, dan Monetary (RFM), menemukan kelompok pelanggan dengan nilai tinggi yang berpotensi memberikan kontribusi terbesar terhadap pendapatan, serta mengidentifikasi pola keterkaitan antar produk yang sering dibeli secara bersamaan untuk mendukung strategi bundling dan rekomendasi produk. Selain itu, hasil analisis diharapkan dapat digunakan untuk mendukung pengambilan keputusan pemasaran yang lebih efektif tanpa memerlukan proses analisis manual yang kompleks oleh pihak bisnis.

Kriteria keberhasilan analitik ditetapkan berdasarkan terbentuknya segmentasi pelanggan yang stabil dan dapat diinterpretasikan secara bisnis menggunakan metode clustering (K-Means) dengan evaluasi Silhouette Score sebagai indikator kualitas cluster, serta terbentuknya association rules yang memiliki nilai support, confidence, dan lift yang memenuhi ambang batas kelayakan untuk digunakan dalam strategi rekomendasi produk.

D. Data Understanding



Gbr. 2 Diagram Alur Fase Data Understanding

Pada fase ini dilakukan pemahaman terhadap data yang digunakan dalam penelitian untuk memastikan kesesuaian data dalam menjawab permasalahan bisnis yang telah

ditetapkan. Tahap ini bertujuan untuk memahami karakteristik data, struktur data, serta kualitas data sebelum dilakukan proses analisis lebih lanjut.


Dataset yang digunakan dalam penelitian ini adalah Online Retail Dataset yang diperoleh dari *UCI Machine Learning Repository*. Dataset ini merupakan data transaksi ritel online yang mencatat aktivitas pembelian pelanggan pada periode Desember 2010 hingga Desember 2011 pada sebuah perusahaan ritel berbasis di Inggris. Data yang digunakan bersifat *transactional-level* data yang mencakup informasi pelanggan, produk, jumlah pembelian, harga satuan, serta waktu transaksi.

Secara keseluruhan, dataset terdiri dari 541909 baris data dengan delapan variabel utama yang meliputi InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, dan Country. Seluruh fitur atau variable tersebut terkategori ke dalam tiga kelompok. Pertama numerik yang meliputi Quantity, UnitPrice, dan CustomerID. Lalu, kategorikal yang meliputi InvoiceNo, StockCode, Description, dan Country. Serta Temporal yang mencakup InvoiceDate. Dataset ini tidak memiliki variabel target secara eksplisit karena analisis yang dilakukan menggunakan pendekatan *Unsupervised Learning* untuk segmentasi pelanggan dan *Association Rule Mining* untuk menemukan pola keterkaitan antar produk.

Di sisi lain, pada tahap eksplorasi awal data ditemukan beberapa karakteristik dalam dataset, seperti terdapat *missing value* pada fitur CustomerID dan Description, data transaksi dengan nilai Quantity negatif yang mengindikasikan adanya pembatalan transaksi (*cancelled transactions*), duplikasi data pada beberapa transaksi, ketidakseimbangan distribusi data seperti sebagian besar transaksi hanya berasal dari negara tertentu, serta distribusi nilai transaksi yang cenderung *skewed* di mana beberapa pelanggan memiliki nilai pembelian sangat tinggi dibandingkan mayoritas pelanggan lainnya.

Untuk memahami pola awal dalam data, dilakukan analisis eksploratif terhadap beberapa aspek utama seperti distribusi transaksi berdasarkan negara, produk yang paling sering dibeli, serta pola transaksi berdasarkan waktu. Hasil eksplorasi menunjukkan adanya konsentrasi transaksi pada produk-produk tertentu serta adanya perbedaan signifikan dalam kontribusi pelanggan terhadap pendapatan perusahaan, di mana sebagian kecil pelanggan memberikan kontribusi yang sangat besar terhadap total penjualan.

E. Data Preparation



Gbr. 3 Diagram Alur Fase Data Preparation

Pada tahap ini dilakukan proses persiapan data sebelum dilakukan pemodelan untuk memastikan data berada dalam kondisi yang bersih, konsisten, dan sesuai dengan kebutuhan analisis. Proses ini mencakup pemilihan data, pembersihan data, transformasi data, serta pembentukan fitur analitis yang digunakan pada tahap *modeling*.

Tahap awal dilakukan dengan melakukan seleksi data dari *Online Retail Dataset*, yaitu dengan hanya menggunakan data transaksi yang valid. Transaksi dengan status pembatalan diidentifikasi berdasarkan nilai InvoiceNo yang diawali dengan huruf “C” dan kemudian dihapus dari dataset. Selain itu, data yang tidak memiliki CustomerID juga dihapus karena tidak dapat digunakan dalam analisis segmentasi pelanggan. Data duplikat juga diidentifikasi dan dihapus untuk menjaga konsistensi dataset.

Pada tahap data cleaning, ditemukan adanya nilai tidak valid seperti Quantity bernilai negatif serta UnitPrice bernilai nol. Data tersebut dianggap sebagai noise dalam dataset transaksi sehingga dilakukan proses filtering untuk memastikan hanya data transaksi yang valid yang digunakan dalam analisis.

Selanjutnya dilakukan tahap transformasi data, di mana variabel InvoiceDate dikonversi menjadi format datetime untuk mendukung analisis berbasis waktu. Selain itu, data transaksi diolah menjadi level pelanggan (customer-level aggregation) untuk kebutuhan segmentasi pelanggan menggunakan pendekatan RFM (Recency, Frequency, Monetary).

Tahap feature engineering dilakukan dengan membentuk tiga variabel utama, yaitu Recency yang merepresentasikan waktu sejak transaksi terakhir pelanggan, *Frequency* yang menunjukkan jumlah transaksi yang dilakukan pelanggan, serta *Monetary* yang merepresentasikan total nilai transaksi


pelanggan. Ketiga fitur ini kemudian digunakan untuk melakukan segmentasi pelanggan.

Sebelum proses *clustering*, dilakukan transformasi tambahan berupa normalisasi data menggunakan *scaling* agar seluruh variabel RFM berada dalam skala yang sebanding sehingga tidak terjadi bias pada proses clustering.

Untuk keperluan *association rule mining*, data juga ditransformasikan ke dalam bentuk transactional basket, di mana setiap transaksi pelanggan dikelompokkan berdasarkan InvoiceNo dan daftar produk yang dibeli. Format ini digunakan sebagai input pada algoritma *FP-Growth* untuk menemukan pola pembelian antar produk.

Secara keseluruhan, tahap *Data Preparation* menghasilkan dataset yang telah bersih, terstruktur, dan siap digunakan untuk proses modeling, baik untuk segmentasi pelanggan menggunakan K-Means maupun analisis pola pembelian menggunakan FP-Growth.

F. Modeling



Gbr. 4 Diagram Alur Fase Modeling

Pada tahap ini dilakukan proses pemodelan data untuk menjawab permasalahan bisnis yang telah didefinisikan sebelumnya. Pendekatan yang digunakan dalam penelitian ini terdiri dari dua metode utama, yaitu segmentasi pelanggan menggunakan RFM Analysis yang dikombinasikan dengan algoritma K-Means Clustering, serta analisis pola pembelian menggunakan *Association Rule Mining* dengan algoritma FP-Growth.

Pada proses segmentasi pelanggan, terlebih dahulu dilakukan pembentukan fitur *Recency*, *Frequency*, dan *Monetary* (RFM) berdasarkan data transaksi pelanggan yang telah diproses pada tahap sebelumnya. *Recency* menunjukkan

waktu sejak transaksi terakhir pelanggan, *Frequency* menunjukkan jumlah transaksi yang dilakukan, sedangkan *Monetary* merepresentasikan total nilai pembelian pelanggan. Ketiga variabel ini kemudian digunakan sebagai dasar untuk mengelompokkan pelanggan berdasarkan perilaku pembelian.

Sebelum dilakukan proses clustering, data RFM dilakukan transformasi menggunakan *log transformation* untuk mengurangi *skewness* pada distribusi data, kemudian dilakukan standarisasi menggunakan *scaling* agar seluruh variabel berada dalam skala yang sama. Hal ini dilakukan untuk menghindari bias dalam proses perhitungan jarak pada algoritma K-Means.

Algoritma K-Means Clustering digunakan untuk mengelompokkan pelanggan ke dalam beberapa segmen berdasarkan kesamaan karakteristik RFM. Jumlah cluster optimal ditentukan menggunakan metode *Elbow Method* yang menunjukkan titik penurunan inertia yang mulai melandai, serta diperkuat dengan evaluasi menggunakan *Silhouette Score* untuk mengukur kualitas pemisahan antar cluster.

Hasil *clustering* kemudian digunakan untuk mengidentifikasi karakteristik masing-masing segmen pelanggan berdasarkan nilai rata-rata RFM, sehingga dapat diperoleh interpretasi bisnis seperti pelanggan bernilai tinggi, pelanggan loyal, maupun pelanggan dengan aktivitas rendah.


Selain segmentasi pelanggan, dilakukan juga analisis pola pembelian menggunakan *Association Rule Mining* dengan algoritma FP-Growth. Pada tahap ini, data transaksi diubah ke dalam format basket, di mana setiap transaksi dikelompokkan berdasarkan InvoiceNo dan daftar produk yang dibeli dalam satu transaksi. Transformasi ini diperlukan agar data sesuai dengan format input algoritma FP-Growth.

Algoritma FP-Growth digunakan untuk menemukan *frequent itemsets* dan menghasilkan *association rules* yang menggambarkan hubungan antar produk yang sering dibeli secara bersamaan. Parameter yang digunakan dalam pembentukan aturan adalah nilai minimum support, confidence, dan lift untuk memastikan bahwa aturan yang dihasilkan memiliki kekuatan hubungan yang signifikan dan dapat diinterpretasikan secara bisnis.

Secara keseluruhan, tahap modeling menghasilkan dua output utama, yaitu model segmentasi pelanggan berbasis K-Means yang mengelompokkan pelanggan berdasarkan perilaku transaksi, serta model association rules yang mengidentifikasi pola keterkaitan antar produk untuk mendukung strategi cross-selling dan rekomendasi produk.

G. Evaluation

Pada tahap ini dilakukan penentuan metode evaluasi untuk mengukur kinerja model yang dibangun dalam penelitian. Evaluasi dilakukan untuk memastikan bahwa hasil model sesuai dengan tujuan analisis yang telah ditetapkan sebelumnya.



Gbr. 5 Diagram Alur Fase Evaluasi Clustering

Evaluasi pada model segmentasi pelanggan menggunakan *K-Means Clustering* dilakukan dengan pendekatan *Elbow Method* untuk menentukan jumlah cluster yang optimal berdasarkan nilai inerti. Selain itu, digunakan *Silhouette Score* sebagai metrik untuk mengukur tingkat pemisahan antar cluster, di mana nilai yang lebih tinggi menunjukkan kualitas clustering yang lebih baik.



Gbr. 6 Diagram Alur Fase Evaluasi Asosiasi

Pada analisis *Association Rule Mining* dengan algoritma FP-Growth, evaluasi dilakukan menggunakan tiga metrik utama, yaitu *support*, *confidence*, dan *lift*. *Support* digunakan untuk mengukur frekuensi kemunculan kombinasi item, *confidence* digunakan untuk mengukur kekuatan hubungan antar item dalam aturan asosiasi, sedangkan *lift* digunakan

untuk mengukur kekuatan hubungan dibandingkan dengan kondisi acak.

Dengan demikian, evaluasi dilakukan untuk memastikan bahwa model yang digunakan dapat menghasilkan segmentasi pelanggan yang representatif serta aturan asosiasi yang memiliki makna dan relevansi terhadap konteks bisnis.

H. Deployment

Tahap deployment adalah tahap terakhir dalam pembuatan aplikasi dengan tujuan untuk mendistribusikan system agar dapat diakses dan digunakan oleh pengguna melalui internet. Pada penelitian ini, Aplikasi Analisis Pola Belanja E-Commerce Menggunakan Association Rule Mining dan K-Means Clustering dirancang menggunakan framework streamlit serta dideploy menggunakan layanan *streamlit community cloud*. Platform ini menyediakan sebuah layanan hosting berbasis cloud secara gratis, mudah digunakan, serta terintegrasi langsung dengan repositori GitHub sehingga memudahkan proses pengelolaan dan pembaruan aplikasi.

Sebelum proses deployment dilakukan, seluruh kode program dan file pendukung terlebih dahulu disimpan ke dalam repositori GitHub. Repositori tersebut berisi *source code* aplikasi, dataset yang digunakan, model hasil analisis, serta berbagai berkas konfigurasi yang diperlukan selama proses *deployment*.

Proses deployment dilakukan dengan menghubungkan repositori GitHub ke layanan *Streamlit Community Cloud*. Setelah repositori berhasil terhubung, sistem secara otomatis melakukan proses build terhadap aplikasi dengan menginstal seluruh dependensi yang tercantum pada file *requirements.txt*. Selanjutnya, *Streamlit Community Cloud* akan menjalankan file utama aplikasi (*app.py*) sebagai entry point sehingga aplikasi dapat diakses secara online melalui URL yang disediakan oleh platform.

Salah satu keunggulan penggunaan *Streamlit Community Cloud* adalah kemampuannya dalam mendukung mekanisme *Continuous Deployment*. Setiap perubahan kode yang diunggah (*push*) ke *branch* utama repositori GitHub akan secara otomatis memicu proses *rebuild* dan *redployment* aplikasi tanpa memerlukan konfigurasi tambahan. Dengan mekanisme tersebut, versi terbaru aplikasi dapat langsung tersedia secara daring sehingga proses pemeliharaan dan pengembangan sistem menjadi lebih efisien.

Setelah *deployment* berhasil dilakukan, aplikasi dapat diakses oleh pengguna melalui perangkat yang terhubung ke internet tanpa perlu melakukan instalasi perangkat lunak tambahan. Pengguna hanya perlu membuka alamat aplikasi menggunakan *web browser* untuk mengakses berbagai fitur yang tersedia, seperti visualisasi data transaksi, segmentasi pelanggan menggunakan K-Means Clustering, analisis pola pembelian menggunakan Association Rule Mining, serta rekomendasi produk berdasarkan hasil analisis yang diperoleh.

IV. HASIL DAN PEMBAHASAN

A. Hasil Data Understanding

Hasil eksplorasi awal terhadap dataset Online Retail menunjukkan bahwa data yang digunakan dalam penelitian ini


merupakan data transaksi ritel dalam skala besar dengan karakteristik transactional dataset. Dataset terdiri dari sekitar 541.909 baris data dengan 8 atribut utama, yaitu InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, dan Country.

	Quantity	InvoiceDate	UnitPrice	\
count	541909.000000	541909	541909.000000	
mean	9.552250	2011-07-04 13:34:57.156386048	4.611114	
min	-80995.000000	2010-12-01 08:26:00	-11062.060000	
25%	1.000000	2011-03-28 11:34:00	1.250000	
50%	3.000000	2011-07-19 17:17:00	2.080000	
75%	10.000000	2011-10-19 11:27:00	4.130000	
max	80995.000000	2011-12-09 12:50:00	38970.000000	
std	218.081158	NaN	96.759853	

	CustomerID
count	406829.000000
mean	15287.690570
min	12346.000000
25%	13953.000000
50%	15152.000000
75%	16791.000000
max	18287.000000
std	1713.600303


Gbr. 7 Hasil Analisis Deskriptif Dataset

Dari hasil analisis deskriptif, diketahui bahwa dataset memiliki variasi tipe data yang terdiri dari numerik, kategorikal, dan temporal. Variabel Quantity dan UnitPrice merepresentasikan aspek kuantitatif transaksi, sedangkan CustomerID dan StockCode merepresentasikan entitas pelanggan dan produk.




Gbr. 8 Distribusi Transaksi

Selain itu, ditemukan bahwa distribusi transaksi tidak merata antar negara. Negara United Kingdom mendominasi jumlah transaksi secara signifikan dibandingkan negara lainnya, yang menunjukkan bahwa mayoritas aktivitas bisnis perusahaan terkonsentrasi pada pasar tertentu. Kondisi ini penting untuk dipertimbangkan dalam analisis bisnis karena dapat mempengaruhi strategi segmentasi pelanggan.



Gbr. 9 Distribusi Tipe Transaksi



Gbr. 10 Hasil Analisis Missing Values

Pada tahap ini juga ditemukan adanya anomali data berupa transaksi dengan Quantity negatif yang mengindikasikan adanya pembatalan transaksi, serta missing value pada variabel CustomerID dan Description yang perlu ditangani pada tahap preprocessing.

B. Hasil Data Preparation

Tahap data preparation dilakukan untuk membersihkan dan mentransformasikan data agar siap digunakan dalam proses pemodelan. Proses ini diawali dengan melakukan filtering terhadap data transaksi yang tidak valid, yaitu transaksi dengan InvoiceNo yang diawali huruf "C" yang menunjukkan transaksi pembatalan. Selain itu, data yang tidak memiliki CustomerID dihapus karena tidak dapat digunakan dalam analisis berbasis pelanggan.

```

Before cleaning: (541909, 9)
After remove cancelled: (532621, 9)
After remove Quantity<=0: (531285, 9)
After remove UnitPrice<=0: (530104, 9)
After remove missing CustomerID: (397884, 9)

✅ Cleaning selesai
Dataset ARM (tanpa CustomerID filter): (530104, 10)
Dataset RFM/Clustering : (397884, 10)

```

Gbr. 11 Hasil Analisis Missing Values


Pada tahap preprocessing, dilakukan pembersihan data untuk memastikan kualitas dataset sebelum dilakukan analisis lebih lanjut. Proses cleaning dimulai dengan menghapus transaksi yang dibatalkan (InvoiceNo yang diawali huruf "C"), sehingga jumlah data berkurang dari 541.909 menjadi 532.621 baris.

Selanjutnya dilakukan penghapusan transaksi dengan $Quantity \leq 0$, sehingga jumlah data menjadi 531.285 baris, dan kemudian dilakukan penghapusan $UnitPrice \leq 0$ yang menghasilkan 530.104 baris data. Setelah itu, dilakukan penghapusan missing value pada CustomerID sehingga dataset akhir untuk analisis RFM menjadi 397.884 baris data.


RFM shape: (4338, 4)

	CustomerID	Recency	Frequency	Monetary
count	4338.00	4338.00	4338.00	4338.00
mean	15300.41	92.54	4.27	2054.27
std	1721.81	100.01	7.70	8989.23
min	12346.00	1.00	1.00	3.75
25%	13813.25	18.00	1.00	307.41
50%	15299.50	51.00	2.00	674.48
75%	16778.75	142.00	5.00	1661.74
max	18287.00	374.00	209.00	280206.02


Gbr. 12 Hasil Analisis Deskriptif RFM



Gbr. 13 Distribusi Recency



Gbr. 14 Distribusi Frequency



Gbr. 15 Distribusi Monetary

Tahap ini memastikan bahwa hanya data transaksi valid yang digunakan dalam proses analisis. Selanjutnya dilakukan pembentukan fitur RFM (Recency, Frequency, Monetary) berdasarkan agregasi data pelanggan. Hasil perhitungan menunjukkan bahwa terdapat 4.338 pelanggan unik yang dianalisis. Selain itu, hasil statistik RFM menunjukkan bahwa rata-rata Recency adalah 92.54, rata-rata Frequency adalah 4.27, dan rata-rata Monetary adalah 2054.27.

Scaled shape: (4338, 3)


	R_scaled	F_scaled	M_scaled
count	4338.000	4338.000	4338.000
mean	-0.000	-0.000	0.000
std	1.000	1.000	1.000
min	-2.341	-0.955	-4.005
25%	-0.661	-0.955	-0.686
50%	0.090	-0.362	-0.062
75%	0.845	0.653	0.654
max	1.564	5.859	4.732

Gbr. 16 Hasil Standarisasi Data RFM


Sebelum digunakan dalam proses clustering, data RFM dilakukan transformasi menggunakan log transformation untuk mengurangi skewness dan kemudian dilakukan standarisasi agar seluruh variabel berada pada skala yang sama. Hasilnya, setiap data memiliki perbedaan rentang yang tidak terlalu signifikan (bisa dilihat di Gbr. 15)

C. Hasil dan Evaluasi Customer Segmentation (RFM & K-Means)

Pada tahap ini, segmentasi pelanggan dilakukan melalui algoritma *K-Means Clustering* berdasarkan fitur RFM yang telah diproses. Kemudian, penentuan jumlah optimal *cluster* dilakukan menggunakan *elbow method*.



Gbr. 17 Plot Metrics Elbow Method




Gbr. 18 Plot Metrics Silhouette Score

Berdasarkan pola yang terlihat pada Gbr. 17, nilai $k=4$ dengan inertia 3939 merupakan jumlah cluster yang optimal. Karena setelah titik tersebut, penurunan inertia mulai melandai. Selain itu, evaluasi model *clustering* menunjukkan bahwa nilai Silhouette Score untuk $k=4$ adalah 0.337 yang menunjukkan bahwa kualitas *clustering* berada pada kategori cukup baik.


Cluster	Recency	Frequency	Monetary	Count	Pct
0	18.12	2.15	551.82	837	19.3
1	12.13	13.71	8074.27	716	16.5
2	71.08	4.08	1802.83	1173	27.0
3	182.50	1.32	343.45	1612	37.2

Cluster Labels:			
Cluster	Label	Count	Pct
0	Potential Loyalists	837	19.3
1	Champions	716	16.5
2	At-Risk / Churned	1173	27.0
3	At-Risk / Churned	1612	37.2


Gbr. 19 Hasil Clustering



Gbr. 20 Boxplot Recency per Cluster



Gbr. 21 Boxplot Frequency per Cluster



Gbr. 22 Boxplot Monetary per Cluster

Kemudian, hasil *clustering* menghasilkan 4 cluster pelanggan dengan karakteristik yang berbeda berdasarkan nilai RFM. Cluster pertama memiliki Recency rendah (sekitar 18 hari), Frequency rendah (2.15 transaksi), dan Monetary rendah (551.82), yang menunjukkan pelanggan dengan aktivitas rendah. Cluster kedua memiliki Recency sangat rendah (12.13 hari), Frequency sangat tinggi (13.71 transaksi), dan Monetary tertinggi (8074.27), sehingga merepresentasikan pelanggan paling bernilai (Champions). Cluster ketiga memiliki Recency sedang (71.08 hari), Frequency 4.08 transaksi, dan Monetary 1802.83, yang menunjukkan pelanggan aktif dengan potensi loyalitas. Sementara itu, cluster keempat memiliki Recency tinggi (182.50 hari), Frequency rendah (1.32 transaksi), dan Monetary rendah (343.45), yang menunjukkan pelanggan tidak aktif atau berisiko churn.

Berdasarkan hasil interpretasi bisnis, keempat cluster tersebut dipetakan menjadi 3 segmen utama pelanggan. Cluster dengan karakteristik paling aktif dan bernilai tinggi

dikategorikan sebagai Champions, cluster dengan aktivitas menengah dikategorikan sebagai Potential Loyalists, sedangkan dua cluster dengan tingkat aktivitas rendah dan tidak aktif digabung menjadi satu kategori yaitu At-Risk / Churned karena memiliki pola perilaku yang serupa dari sisi rendahnya Frequency dan Monetary serta tingginya Recency. Dengan demikian, meskipun algoritma K-Means menghasilkan 4 cluster, secara analisis bisnis hanya terdapat 3 segmen utama yang lebih representatif untuk interpretasi.



Gbr. 23 Boxplot Monetary per Cluster

Untuk memvalidasi hasil clustering, dilakukan visualisasi menggunakan Principal Component Analysis (PCA) yang mereduksi dimensi RFM menjadi dua komponen utama. Hasil visualisasi menunjukkan bahwa cluster Champions terpisah dengan jelas pada area dengan nilai PCA positif, sedangkan cluster At-Risk/Churned tersebar pada area dengan nilai PCA negatif dan lebih menyebar. Cluster Potential Loyalists berada di area transisi di antara kedua kelompok tersebut. Secara keseluruhan, hasil PCA menunjukkan bahwa pemisahan antar cluster cukup baik meskipun masih terdapat sedikit overlap antara cluster dengan karakteristik aktivitas rendah.

D. Hasil dan Evaluasi Asosiasi Rule Mining (FP-Growth)

Transaksi United Kingdom: 485,123
Basket matrix shape: (18019, 4007)
Density: 0.0066


Gbr. 24 Hasil Basket Matrix

Pada tahap ini dilakukan analisis pola pembelian menggunakan metode Association Rule Mining dengan algoritma FP-Growth untuk menemukan hubungan antar produk yang sering dibeli secara bersamaan. Data transaksi terlebih dahulu diubah ke dalam bentuk basket berdasarkan InvoiceNo sehingga setiap transaksi merepresentasikan kumpulan item yang dibeli dalam satu waktu. Proses ini menghasilkan frequent itemsets dengan nilai minimum support sebesar 0.02 (2% transaksi), yang kemudian digunakan untuk membentuk association rules dalam bentuk “jika membeli produk A maka cenderung membeli produk B”.

Total rules: 184					
Top 10 rules by Lift:					
	antecedents	consequents	support	confidence	lift
167	(WOODEN HEART CHRISTMAS SCANDINAVIAN)	(WOODEN STAR CHRISTMAS SCANDINAVIAN)	0.020423	0.722866	27.197263
166	(WOODEN STAR CHRISTMAS SCANDINAVIAN)	(WOODEN HEART CHRISTMAS SCANDINAVIAN)	0.020423	0.768267	27.197263
180	(GREEN REGENCY TEACUP AND SAUCER, ROSES REGENCY...	(PINK REGENCY TEACUP AND SAUCER)	0.027395	0.702857	18.041001
181	(PINK REGENCY TEACUP AND SAUCER)	(GREEN REGENCY TEACUP AND SAUCER, ROSES REGENCY...	0.027395	0.700855	18.041001
182	(GREEN REGENCY TEACUP AND SAUCER)	(PINK REGENCY TEACUP AND SAUCER, ROSES REGENCY...	0.027395	0.527897	17.453534
179	(PINK REGENCY TEACUP AND SAUCER, ROSES REGENCY...	(GREEN REGENCY TEACUP AND SAUCER)	0.027395	0.902752	17.453534
178	(PINK REGENCY TEACUP AND SAUCER, GREEN REGENCY...	(ROSES REGENCY TEACUP AND SAUCER)	0.027395	0.854167	16.099612
183	(ROSES REGENCY TEACUP AND SAUCER)	(PINK REGENCY TEACUP AND SAUCER, GREEN REGENCY...	0.027395	0.514644	16.099612
175	(GREEN REGENCY TEACUP AND SAUCER)	(PINK REGENCY TEACUP AND SAUCER)	0.031966	0.618026	15.863541
174	(PINK REGENCY TEACUP AND SAUCER)	(GREEN REGENCY TEACUP AND SAUCER)	0.031966	0.82613	15.863541

Gbr. 25 Hasil Pembentukan Association Rules

Hasil pembentukan *association rules* dievaluasi menggunakan tiga metrik utama yaitu support, confidence, dan lift. Support menunjukkan frekuensi kemunculan aturan dalam dataset, confidence menunjukkan tingkat kepercayaan terhadap aturan, sedangkan lift mengukur kekuatan hubungan antar produk dibandingkan dengan kondisi acak. Dari hasil analisis diperoleh beberapa aturan dengan nilai yang cukup tinggi, misalnya aturan WOODEN HEART CHRISTMAS SCANDINAVIAN -> WOODEN STAR CHRISTMAS SCANDINAVIAN dengan support sebesar 0.0204, confidence 0.7229, dan lift 27.19, yang menunjukkan hubungan sangat kuat antar kedua produk tersebut. Selain itu, terdapat aturan lain seperti GREEN REGENCY TEACUP AND SAUCER + ROSES REGENCY TEACUP AND SAUCER -> PINK REGENCY TEACUP AND SAUCER dengan support 0.0273, confidence 0.7028, dan lift 18.04, yang juga menunjukkan adanya pola pembelian yang kuat pada kategori produk tertentu.



Gbr. 26 Visualisasi Association Rules

Berdasarkan hasil visualisasi, sebagian besar aturan berada pada rentang support rendah hingga menengah (sekitar 0.02 hingga 0.04) dengan nilai confidence yang bervariasi antara 0.3 hingga 0.9. Beberapa aturan dengan nilai lift tinggi (di atas 20) terlihat sebagai titik yang lebih besar dan berwarna hijau, yang menunjukkan adanya hubungan yang sangat kuat antar produk dan tidak terjadi secara kebetulan. Sebaliknya, aturan dengan lift rendah cenderung berada pada area berwarna merah dengan ukuran titik yang lebih kecil, yang menunjukkan hubungan yang lemah antar item.

Secara keseluruhan, hasil association rule mining menunjukkan bahwa terdapat pola keterkaitan antar produk yang signifikan, terutama pada produk-produk tertentu dalam kategori dekorasi dan perlengkapan rumah. Pola ini dapat dimanfaatkan untuk strategi cross-selling, product bundling, serta sistem rekomendasi produk yang lebih personal guna meningkatkan nilai transaksi pelanggan.

V. IMPLEMENTASI SISTEM

A. Arsitektur Sistem

Implementasi sistem dibangun dalam dua komponen utama yang saling terintegrasi. Komponen pertama berupa pipeline pemrosesan data yang dijalankan menggunakan Google Colab. Pada tahap ini dilakukan seluruh proses analisis data, mulai dari pembersihan data (data cleaning), transformasi data, perhitungan metrik RFM (Recency, Frequency, Monetary), pembentukan model menggunakan algoritma FP-Growth untuk analisis pola pembelian dan K-Means untuk segmentasi pelanggan, hingga evaluasi hasil clustering. Seluruh model dan artefak yang dihasilkan kemudian disimpan menggunakan


library Joblib agar dapat digunakan kembali tanpa perlu melakukan pelatihan ulang.

Komponen kedua berupa aplikasi web berbasis Streamlit yang berfungsi sebagai media implementasi dan visualisasi hasil analisis. Aplikasi ini memanfaatkan model serta dataset yang telah dihasilkan pada tahap sebelumnya sehingga pengguna dapat melakukan eksplorasi data, melihat hasil segmentasi pelanggan, dan menganalisis pola pembelian secara interaktif melalui antarmuka web.

Pipeline pemrosesan menghasilkan beberapa artefak yang disimpan pada direktori my-streamlit-app/. Artefak tersebut terdiri atas kmeans_model.pkl sebagai model clustering pelanggan menggunakan algoritma K-Means, scaler.pkl sebagai objek StandardScaler untuk proses normalisasi data, serta pca_model.pkl sebagai model Principal Component Analysis (PCA) yang digunakan untuk reduksi dimensi dan visualisasi kluster pelanggan.

Selain artefak model, sistem juga menyimpan beberapa dataset pendukung, yaitu rfm_clustered.csv yang berisi hasil segmentasi pelanggan berdasarkan analisis RFM dan K-Means, frequent_itemsets.csv yang berisi kombinasi item yang sering muncul bersamaan hasil proses FP-Growth, association_rules.csv yang berisi aturan asosiasi yang terbentuk dari frequent itemsets, serta transactions_clean.csv yang merupakan dataset transaksi yang telah melalui tahap pembersihan data.

Seluruh artefak dan dataset tersebut dimuat ketika aplikasi Streamlit dijalankan sehingga proses visualisasi dan analisis dapat dilakukan secara efisien tanpa perlu mengulangi proses pelatihan model. Dengan pendekatan ini, aplikasi mampu memberikan respons yang lebih cepat dan mendukung pengalaman pengguna yang lebih baik.




Gbr. 27 Arsitektur Sistem

B. Halaman Home

Halaman Home pada aplikasi Retail Intelligence berfungsi sebagai landing page atau pintu masuk utama aplikasi analitik ritel berbasis Streamlit. Berdasarkan struktur navigasi dan fungsi aplikasi, halaman ini dirancang untuk memberikan gambaran singkat mengenai tujuan sistem, fitur utama, dan alur penggunaan sebelum pengguna berpindah ke menu analisis lainnya.


Pada halaman home terdapat beberapa informasi Penjelasan singkat mengenai aplikasi, Penjelasan singkat proyek, Anggota tim yang membangun aplikasi, ringkasan dataset, segmen pelanggan, Penjelasan fitur yang ada di dashboard.



Gbr. 28 Halaman Home


C. Halaman Dataset Overview

Halaman ini berisi penjelasan mengenai dataset yang digunakan, terdapat tiga bagian utama, pertama ada informasi mengenai dataset yang digunakan nama, sumber, periode data, negara asal, format, lisensi, serta berisi jumlah baris dan kolom/fitur yang digunakan



Gbr. 29 Halaman Dataset Overview Bagian Pertama

Bagian kedua merupakan statistic deskriptif RFM yang merupakan analisis yang digunakan untuk menggambarkan karakteristik pelanggan berdasarkan tiga aspek utama, yaitu Recency, Frequency, dan Monetary (RFM). Menampilkan hasil dari analisis Recency, Frequency, dan Monetary serta ada sub-menu untuk menampilkan 10 baris pertama sample data transaksi



Gbr. 30 Halaman Dataset Overview Bagian Kedua


Pada bagian ketiga terdapat distribusi data yang menampilkan distribusi data, terdapat empat diagram yang membahas hasil dari RFM, Distribusi Recency merupakan jumlah hari sejak transaksi terakhir pelanggan, Distribusi Monetary yang menunjukkan total nilai pembelian pelanggan, Distribusi Frequency yang merupakan frekuensi transaksi pelanggan, dan Jumlah pelanggan per segmen yang menunjukkan hasil segmentasi pelanggan berdasarkan nilai RFM. Terdapat tiga segmen yang mengelompokkan setiap pelanggan, champions merupakan pelanggan terbaik sering bertransaksi dan nilai pembelian tinggi sehingga perlu diberi reward atau promo, kedua ada potential loyalis pelanggan yang cukup aktif dan berpotensi menjadi pelanggan setia, ketiga At-risk/Churned pelanggan yang sudah lama tidak bertransaksi.




Gbr. 31 Halaman Dataset Overview Bagian Ketiga

D. Halaman Analisis Pelanggan

Halaman Analisis pelanggan berfungsi sebagai tempat eksekusi untuk mendapat informasi terkait pola pembelian customer dan segmentasi pelanggan. Analisis pola pembelian pelanggan terdapat dua sub menu, pertama bisa melalui ID Customer dimana user diminta memilih id customer yang ingin di analisis lalu akan keluar output berupa rekomendasi




Gbr. 32 Halaman Analisis Pelanggan




Gbr. 33 Halaman Analisis Pelanggan Tab Profil Pelanggan


User juga bisa melakukan analisis manual dengan menggabungkan beberapa produk untuk mencari pola pembelian pelanggan yang nanti akan diberikan rekomendasi produk berdasarkan pola pembelian jika memang ada korelasinya



Gbr. 34 Halaman Analisis Pola Produk




Gbr. 35 Halaman Hasil Analisis Pola Produk




Gbr. 36 Halaman Detail Aturan Asosiasi

Selain analisis pola pembelian pelanggan juga terdapat sub-menu segmentasi pelanggan yang digunakan untuk memprediksi kategori pelanggan baru berdasarkan metode RFM (Recency, Frequency, Monetary) dan model K-Means Clustering yang telah dilatih sebelumnya. Pengguna dapat memasukkan nilai karakteristik pelanggan, kemudian sistem akan menentukan segmen pelanggan secara otomatis.




Gbr. 37 Halaman Segmentasi Pelanggan




Gbr. 38 Halaman Hasil Segmentasi Pelanggan

E. Halaman Visualization


Halaman Visualization berfungsi untuk menyajikan hasil analisis data pelanggan dalam bentuk grafik dan diagram yang lebih mudah dipahami. Visualisasi ini membantu pengguna mengidentifikasi pola perilaku pelanggan, distribusi nilai RFM, serta hasil segmentasi pelanggan secara intuitif tanpa harus membaca data mentah. Terdapat beberapa sub-menu dari distribusi segmen pelanggan, kluster pelanggan PCA, Profil RFM rata-rata per segmen, sebaran recency per-segmen, dan sebaran monetary per-segmen.



Gbr. 39 Halaman Visualisasi Analisis Data Pelanggan 1




Gbr. 40 Halaman Visualisasi Tab Profil RFM Rerata per Segmen



Gbr. 41 Halaman Visualisasi Analisis Data Pelanggan 2


Selain itu, di dalam halaman visualization juga terdapat sub-menu tren penjualan sebagai berikut.




Gbr. 42 Halaman Visualisasi Tren Penjualan

F. Halaman About


Halaman About merupakan halaman informasi yang menjelaskan profil aplikasi Retail Intelligence, tujuan pengembangan sistem, metode yang digunakan, serta informasi mengenai pengembang aplikasi. Halaman ini berfungsi sebagai dokumentasi singkat agar pengguna dapat memahami latar belakang dan fungsi utama sistem yang dikembangkan.



Gbr. 43 Halaman About Tab Metode



Gbr. 44 Halaman About Tab Dataset



Gbr. 44 Halaman About Tab Dataset

VI. KESIMPULAN

Penelitian ini berhasil mengembangkan aplikasi analisis pola belanja e-commerce yang mengintegrasikan dua metode data mining, yaitu K-Means Clustering untuk segmentasi pelanggan dan FP-Growth untuk analisis pola pembelian. Proses pengembangan dilakukan menggunakan kerangka kerja CRISP-DM yang memungkinkan alur analisis yang sistematis dan terukur dari tahap pemahaman bisnis hingga deployment sistem.

Dari sisi segmentasi pelanggan, algoritma K-Means dengan jumlah cluster optimal $k=4$ berhasil mengidentifikasi tiga segmen utama pelanggan, yaitu Champions, Potential

Loyalists, dan At-Risk/Churned. Segmen Champions menunjukkan karakteristik transaksi yang sangat aktif dengan nilai pembelian tertinggi, sedangkan segmen At-Risk/Churned memiliki tingkat aktivitas yang rendah dan berpotensi meninggalkan platform. Hasil evaluasi clustering menunjukkan Silhouette Score sebesar 0.337, yang mengindikasikan pemisahan antar segmen pada kategori cukup baik.

Pada analisis pola pembelian, algoritma FP-Growth berhasil menemukan association rules yang signifikan dengan nilai lift tertinggi mencapai 27.19. Hal ini menunjukkan adanya kecenderungan kuat bahwa pembelian produk tertentu diikuti oleh pembelian produk lain dalam satu transaksi, khususnya pada kategori dekorasi dan perlengkapan rumah. Pola ini dapat langsung dimanfaatkan untuk strategi cross-selling dan product bundling.

Secara keseluruhan, aplikasi yang dibangun menggunakan Streamlit dan di-deploy melalui Streamlit Community Cloud terbukti mampu menyajikan hasil analisis secara interaktif dan mudah diakses. Penelitian ini menunjukkan bahwa kombinasi RFM Analysis, K-Means Clustering, dan FP-Growth merupakan pendekatan yang efektif untuk menggali wawasan bisnis dari data transaksi e-commerce, dan hasil yang diperoleh dapat menjadi dasar yang kuat bagi pengambilan keputusan pemasaran yang lebih personal dan berbasis data.

REFERENSI

- Putri Kausara, K. A., & Sulistyono, M. T. (2026). Comparative Analysis of Association Rule Mining Algorithms Using Apriori and Eclat on Retail Transaction Data. *Journal of Applied Informatics and Computing*, 10(2), 1622–1630. <https://doi.org/10.30871/jaic.v10i2.12122>
- Putri, Y. ., Aldo, D. ., & Ilham, W. (2024). Retail Marketing Strategy Optimization: Customer Segmentation with Artificial Intelligence Integration and K-Means Clustering. *Sinkron : Jurnal Dan Penelitian Teknik Informatika*, 8(4), 2155–2163. <https://doi.org/10.33395/sinkron.v8i4.14000>
- Novela, M., & Basaruddin, T. (2021). Dataset suara dan teks berbahasa Indonesia pada rekaman podcast dan talk show. *Jurnal Fasilkom*, 11(2), 61–66. <https://doi.org/10.37859/jf.v11i2.2628>
- Mabrur, A. G., & Lubis, R. (2012). Penerapan data mining untuk memprediksi kriteria nasabah kredit. *Jurnal Komputer Dan Informatika (KOMPUTA)*, 1(1), 53–57.
- Kurniawan, D., & Yasir, M. (2022). Optimization Sentimen Analysis using CRISP-DM and Naive Bayes Methods Implemented on Social Media. *Cyberspace: Jurnal Pendidikan Teknologi Informasi*, 6(2), 74–85.
- Gunadi, G., & Sensuse, D. I. (2012). Penerapan metode data mining market basket analysis terhadap data penjualan produk buku dengan menggunakan algoritma apriori dan frequent pattern growth (fp-growth): studi kasus percetakan pt. Gramedia. *Telematika Mkom*, 4(1), 118–132.
- Hermawan, A., Wicaksono, B., Ahmadjayadi, T., Prakasa, B. S., & Aruan, J. D. (2024). Implementasi Algoritma Apriori pada Market Basket Analysis terhadap Data Penjualan Produk Supermarket. *Algoritma: Jurnal Matematika, Ilmu pengetahuan Alam, Kebumihan dan Angkasa*, 2(5), 95–105. <https://doi.org/10.62383/algoritma.v2i5.137>
- Kamil, F., Salkiawati, R., & Alexander, A. D. (2023). Analisis Churn Pelanggan Produk Fashion Campus Menggunakan Metode RFM Analysis dan Algoritma Naïve Bayes (Studi Kasus Yayasan Bakti Achmad Zaky). *Jurnal Esensi Infokom: Jurnal Esensi Sistem Informasi dan Sistem Komputer*. <https://doi.org/10.55886/infokom.v7i2.629>
- Hendrastuty, N. (2024). Penerapan Data Mining Menggunakan Algoritma K-Means Clustering Dalam Evaluasi Hasil Pembelajaran

- Siswa. Jurnal Ilmiah Informatika dan Ilmu Komputer (JIMA-ILKOM), 3(1), 46-56. <https://doi.org/10.58602/jima-ilkom.v3i1.26>
- [10] Tahir, M., & Sitompul, N. (2021). Penerapan algoritma FP-Growth dalam menentukan kecenderungan mahasiswa mengambil mata kuliah pilihan. *Network Engineering Research Operation (NERO)*, 6(1), 59.
- [11] Samosir, F. V. P., Mustamu, L. P., Anggara, E. D., Wiyogo, A. I., & Widjaja, A. (2021). Exploratory Data Analysis terhadap Kepadatan Penumpang Kereta Rel Listrik. *Jurnal Teknik Informatika Dan Sistem Informasi*, 7(2), 449-467. <https://doi.org/10.28932/jutisi.v7i2.3700>
- [12] Rema, F. X. (2021). Penerapan metode principal component analysis (PCA) terhadap faktor-faktor yang mempengaruhi lamanya penyelesaian skripsi mahasiswa Program Studi Pendidikan Matematika FKIP UNDANA. *Jurnal Cendekia: Jurnal Pendidikan Matematika*.

LAMPIRAN

Keterangan	Tautan
Dataset	https://archive.ics.uci.edu/dataset/352/online+retail
Aplikasi	https://retail-intelligence-main.streamlit.app/
Video Presentasi dan Demo	https://drive.google.com/drive/folders/10NTi xyZAVdKbkWhrFMqp-TY3BkgMDqSE?usp=sharing
Notebook	https://colab.research.google.com/drive/1TCt jNb9d2KGpkEkyHkOVYwhNejhg4UTF?usp=sharing
Repository Project	https://github.com/vikoxd/my-streamlit-app.git